软件需求规格说明书

1. 引言

1.1 目的

本文规定“智能体动态记忆管理”系统在长程、多会话问答场景中必须满足的功能需求、外部接口需求、非功能需求和评测要求。本文用于指导里程碑 4 的设计、编码与测试，并作为最终验收依据。

1.2 文档约定

- “必须”表示验收前必须满足；“应”表示预期满足且需说明偏差；“可”表示可选能力。
- 本文件不重复定义数据结构与函数签名；字段、默认值和异常类型以 `interfaces.md` 为准。
- 需求编号用于交叉引用和追踪：`FE` 为系统功能，`FR` 为功能需求，`NFR` 为非功能需求，`C` 为约束，`A` 为假设或依赖，`M` 为评测指标。
- 优先级采用“必须、应该、可选”三级。无特别说明时，第 3 章中的功能需求均为“必须”。

1.3 预期读者与阅读建议

读者	主要关注章节	阅读建议
课程教师与助教	1、3、4、5、6	从范围、功能需求、外部接口和验收标准判断交付完整性
项目开发成员	全文	先读第 2 章了解边界，再按第 3、4、5 章实现并验证；数据字段查阅 `interfaces.md`
课程评测人员	3.5、4、6	重点确认命令行入口、数据隔离、指标和输出要求
后续维护者	1.2、2、4、附录 A–B	先读术语、依赖和接口，再阅读数据流模型

1.4 项目范围

系统基于课程指定的 LoCoMo 长对话子集，覆盖“结构化记忆构建 → 有效记忆检索 → 动态状态解析与有效记忆选择 → 答案生成 → Web 可视化 → 三指标评测与基线对照”的完整链路。

系统目标是保留历史事实，并在回答当前问题时区分有效状态与已更新状态。范围外内容包括：多模态数据、跨对话记忆共享、模型训练或微调、面向公网的部署，以及物理设备控制。

1.5 参考资料

- 项目文档：`proposal.md`、`interfaces.md`、`memory-design.md`。
- LoCoMo 数据与评测代码：https://github.com/snap-research/locomo。
- Maharana A, et al. *Evaluating Very Long-Term Conversational Memory of LLM Agents*. ACL 2024.

2. 总体描述

2.1 产品视角

本系统是面向课程数据的一体化记忆问答应用，不是通用聊天机器人。系统每次处理一段独立对话，通过版本化 `MemoryBundle` 连接离线记忆构建、在线检索与推理、Web 展示和课程评测。

```
locomo.json
    → SourceTurn / MemoryBundle
    → RetrievalResult
    → MemoryRelation / AnswerRecord
    → Web 页面或课程评测 answers.json
```

系统依赖课程数据、DeepSeek 官方接口和本地 MiniLM 模型；内部模块的数据契约由 `interfaces.md` 规定。

2.2 产品功能概览

编号	功能	优先级	交付价值
FE-01	结构化记忆构建与存储	必须	将原始对话转换为可追溯、带版本的原子事实
FE-02	有效记忆候选检索	必须	通过关键词、向量及混合召回缩小状态判定范围
FE-03	动态状态解析与答案生成	必须	判定 RETAIN、UPDATE、SUPERSEDE、CONFLICT，并依据有效记忆作答
FE-04	Web 记忆与状态可视化	必须	展示记忆、原始证据和状态演化，支持人工核验与课堂演示
FE-05	评测与课程接口	必须	生成课程要求的答案文件，计算三项指标并完成基线对照

2.3 用户类别与特征

用户类别	特征与需求
项目开发成员	选择对话和问题，检查答案、候选记忆、有效记忆及证据，用于开发集调试
课程教师与课堂听众	通过固定演示流程理解系统如何处理状态变化，不要求具备系统内部实现知识
课程评测人员或评测脚本	按命令行接口批量提交问题、读取答案并计算指标；不依赖 Web 页面是否运行
后续维护者	需要依赖清晰的数据契约、构建版本和可重复的命令，以定位和修改模块

2.4 运行环境

项目	要求
语言与运行时	Python 3.11，版本由 `.python-version` 固定
操作系统	macOS 与 Windows 双平台可运行；路径使用 `pathlib`，文本读写显式使用 UTF-8
外部依赖	DeepSeek 官方 API；调用时关闭 thinking。本地 MiniLM 模型固定 revision，不需要 embedding API key
网络条件	记忆抽取和答案生成需要联网；检索、存储、Web 展示可在本地离线运行

2.5 设计与实现约束

编号	约束
C-01	使用私有 GitHub 仓库和 Ruleset 保护 `main`；所有改动通过分支和 PR 合入，至少一名非作者 Approve，仅允许 Squash merge
C-02	不配置 CI；本地 `pre-commit`（ruff、大文件和私钥检查）与 `pytest` 是自动检查环节
C-03	不提交真实密钥、`.env`、课程数据集或大型模型输出；运行产物写入已忽略目录
C-04	QA 标注区不得进入记忆构建或检索索引；标准答案、gold evidence、标注摘要和问题类型标签不得进入模型输入
C-05	所有规则必须通用，禁止针对具体题目写死答案或按关键词进行定向处理
C-06	历史事实不得在记忆构建阶段删除；旧状态是否有效只能由查询驱动的状态解析决定

2.6 用户文档

根目录 `README.md` 提供安装、数据放置、运行和评测入口说明；`src/README.md` 说明各模块当前能力与限制；Web 页面必须提供字段标签、空状态和可理解的错误提示；`.env.example` 说明必需环境变量，但不得包含真实值。

2.7 假设与依赖

编号	假设或依赖
A-01	课程提供 LoCoMo 原始格式数据，文件位于仓库根目录并命名为 `locomo.json`
A-02	最终测试对话和题目在交付前可能不公开；系统必须在未见过的对话上运行
A-03	DeepSeek 服务和本地模型能够在约定环境中加载；模型超时、限流和非法输出按需求中的重试与失败策略处理

3. 系统功能

3.1 结构化记忆构建与存储

3.1.1 描述与优先级

将课程对话中的文本、说话人、会话时间、轮次来源以及人物、事件、时间和状态事实转换为有来源、可持久化的原子 Memory。该功能是全部在线功能的输入基础，优先级为“必须”。逐轮 `turns` 模式只用于基线和离线联调，不能替代真实语义抽取。

3.1.2 刺激—响应序列

- 输入 `sample_id`：系统读取对应对话并返回清洗后的 SourceTurn 列表。
- 发起记忆构建：系统按会话分块抽取事实，保留新旧事实，输出 Memory 和 `build_id`。
- 请求保存：系统校验 schema、唯一 ID 和来源一致性，原子写入 UTF-8 JSON；校验失败时拒绝覆盖原文件。

3.1.3 功能需求

编号	需求	输入 / 处理 / 输出 / 异常	验收依据	实现位置
FR-01	按对话读取和清洗原始文本	输入：LoCoMo 文件、`sample_id`；处理：按会话及轮次原序读取，移除图片链接和纯图片轮次，仅保留原文、说话人、时间和轮次 ID；输出：SourceTurn 列表；异常：文件缺失、未知或重复对话、轮次 ID 错误时明确报错，未知时间保留 `null` 并警告	改写 QA、答案和标注摘要后构建结果不变；清洗后无图片链接；不同对话来源不混用；合法空对话返回空列表	`src/memory/locomo.py`
FR-02	抽取人物、事件、时间和状态事实	输入：FR-01 的原始轮次；处理：按会话分块调用 DeepSeek，保留新旧事实，用会话日期辅助解析相对时间；输出：有原始来源的原子 Memory，未知字段留空；异常：越界来源、非法 JSON、截断输出有界重试，失败时不导出伪成功结果	Mock 验证字段、来源、重试与缓存；真实单段对话核对人物、事件、状态、时间和原文支持性；记录样本与误差，不用 Mock 代替真实质量验证	`src/memory/build.py`、`extract.py`
FR-03	持久化可追溯、带版本的记忆	输入：合法 MemoryBundle；处理：校验 schema、唯一 ID、来源和时间一致性，原子写入 UTF-8 JSON；输出：可重新加载的完整 bundle 及 `build_id`；异常：不兼容 schema、重复 ID、缺失或跨对话来源拒绝保存，并保留原文件	保存后加载对象一致；同输入、配置和缓存结果产生相同 `build_id` 与 Memory ID；输入或结果变化时版本改变；索引拒绝混用不同 bundle	`src/common/models.py`、`json_io.py`、`src/memory/store.py`

3.2 有效记忆候选检索

3.2.1 描述与优先级

从指定对话的 MemoryBundle 中产生供后续状态解析使用的候选记忆。检索先限定对话，并在截取候选前应用显式过滤条件；不得因为问题包含“当前”就提前删除旧事实。优先级为“必须”。

3.2.2 刺激—响应序列

- 关键词查询：系统执行 BM25 排名并返回不超过 K 条带分数的 Memory 命中。
- 语义或混合查询：系统执行向量检索或 BM25 + 向量 RRF 融合，去重后返回 Top-K 和 trace。
- 证据或历史请求：系统按来源读取原始轮次或关联历史，返回与初始 Top-K 分离的结果。

3.2.3 功能需求

编号	需求	输入 / 处理 / 输出 / 异常	验收依据	实现位置
FR-04	关键词候选检索	输入：索引、对话 ID、问题、K 和可选过滤；处理：BM25 排名；输出：不超过 K 条有序命中，带分数、Memory 和构建身份；异常：空问题、非法 K、跨对话请求报错；无词项交集返回空命中	来源已知的合成查询命中目标轮次；重复查询排序一致；过滤先于截取；`top_k` 为正整数且不大于 `candidate_k`	`src/index/bm25.py`
FR-05	语义候选检索	输入同 FR-04；处理：固定版本 MiniLM 编码、余弦相似度排名、复用带构建与模型身份的缓存；输出：有序 Top-K 及模型和通道信息；异常：模型缺失、超 token 上限、缓存损坏或维度非法时明确报错	真实模型本地运行且来源可回溯；缓存重载与首次结果一致；身份变化不复用旧缓存；模型测试与真实运行分别记录	`src/index/embeddings.py`、`bm25.py`
FR-06	混合召回与去重	输入同 FR-04，模式为 `hybrid`；处理：两路各取 `candidate_k`，按 Memory ID 去重并用等权 RRF 合并；输出：最终 Top-K、各路分数与排名、trace；异常：任一路失败即报错，不伪装成成功融合	同一 Memory 最多出现一次；按融合分降序、同分按 ID 排序；分数均为有限值；结果可追溯到各路候选	`src/index/bm25.py`
FR-07	证据回溯与关联历史读取	输入：当前 bundle 与 Memory ID 或来源引用，或实体、属性及排除 ID；处理：读取原轮次或按原文顺序取关联历史；输出：去重来源、历史列表及 `truncated` 标记；异常：来源或记忆不存在、`limit` 非法时报错	每条候选均可回溯原文；旧状态保留；历史结果与初始 hits 分开；返回对象被修改不污染存储	`src/memory/store.py`、`src/index/context.py`

3.3 动态状态解析与答案生成

3.3.1 描述与优先级

系统根据问题分析结果，对同一实体和属性的候选记忆判断时效关系，形成当前有效记忆集合并生成可追溯答案。该功能是关键路径，优先级为“必须”。

3.3.2 刺激—响应序列

- 接收问题：系统抽取实体、时间范围、时间表达、属性和置信度。
- 接收候选 Memory：系统按实体和属性分组，判定 RETAIN、UPDATE、SUPERSEDE 或 CONFLICT。
- 接收有效关系和候选记忆：系统组装版本化 prompt，调用 DeepSeek 生成一句话答案和 AnswerRecord。
- 构建版本不匹配：系统抛出 `RuntimeError` 并要求重建索引，不返回跨 bundle 结果。

3.3.3 功能需求

编号	需求	输入 / 处理 / 输出 / 异常	验收依据	实现位置
FR-08	从问题中抽取状态判定关键要素	输入：问题文本、`conversation_id`；处理：调用 DeepSeek 官方接口并关闭 thinking，抽取 `entity`、`time_scope`、`time_expression`、`attribute`、`confidence`；输出：符合 `interfaces.md` 契约的 JSON；异常：非法 JSON 重试 2 次，仍失败则记录日志并中断该题，不输出假成功	开发集问题 `attribute` 非空率和 JSON 可解析率均为 100%；`time_scope` 抽样人工核对准确率不低于 80%；字段与 `interfaces.md` 一致	`src/reasoning/query_analyzer.py`
FR-09	判定候选记忆的时效关系	输入：候选 Memory，含内容、实体、属性、时间和来源；处理：仅比较相同 `(entity, attribute)` 组，综合时间和上下文判定；双方时间均缺失时判为 CONFLICT，跨组直接视为 RETAIN；输出：MemoryRelation 列表及 reason、sources；异常：非法 JSON 重试 2 次，仍失败降级为 CONFLICT 并记录日志	输出 100% 符合 schema；开发集总体判定准确率不低于 70%，并报告四类混淆矩阵；时间缺失样本 100% 判为 CONFLICT；跨组记忆不触发模型调用；相同输入与 prompt 版本结果一致	`src/reasoning/relation_judge.py`
FR-10	选择有效记忆并生成答案	输入：MemoryRelation、Query 分析结果和候选 Memory；处理：RETAIN 全保留，UPDATE 合并，SUPERSEDE 只保留新值，CONFLICT 双留并标记；调用版本化 prompt 生成答案；输出：含 `question_id`、`answer`、`valid_memory_ids`、`conflict`、`build_id` 的 AnswerRecord；异常：生成失败重试 2 次，仍失败输出空答案并记录日志，不中断批量评测	SUPERSEDE 场景旧值 100% 不进入答案生成；冲突样本抽检 100% 包含冲突说明；引用记忆均可回溯原始轮次；答案符合课程接口；记录每题 token 消耗	`src/reasoning/memory_selector.py`、`answer_generator.py`
FR-11	保证状态解析与答	输入：AnswerRecord 与 MemoryRelation；处理：携带 `build_id` 和被引用 Memory ID，证据键统一为 `(conversation_id, session_id, turn_id)`；输出：可供评测和前端消费的结构化结果；异	每条答案和关系均含 `build_id`；有效记忆与来源均可定位，定位失败率为 0；Recall@K 证据对齐	`src/reasoning/`

	案可追溯	常：引用 `build_id` 与当前 bundle 不一致时抛出 `RuntimeError`	使用同一口径	

3.4 网页记忆与状态可视化

3.4.1 描述与优先级

Web 界面用于浏览和解释系统结果，调用现有 Memory、来源读取、检索和推理模块，不在前端重新推断状态关系。该功能用于人工核验和课堂演示，优先级为“必须”。

3.4.2 刺激—响应序列

- 选择对话：系统显示该构建下的 Memory 列表、筛选结果和 `build_id`。
- 打开记忆：系统显示 Memory 详情及其原始证据轮次。
- 提交问题：系统显示答案、被引用 Memory 和可用证据入口，不保留上一题状态。
- 查看关系：系统按方向显示四类关系，并可跳转到证据详情。

3.4.3 功能需求

编号	需求	输入 / 处理 / 输出 / 异常	验收依据	实现位置
FR-12	按对话浏览结构化记忆	输入：`conversation_id` 与可选分页或筛选条件；处理：读取当前 MemoryBundle，按稳定顺序展示内容、实体、属性、时间和来源数量；输出：记忆列表及 `build_id`，空对话显示空状态；异常：未知对话、非法分页参数或 bundle 不可读时返回明确错误，不展示其他对话或旧构建内容	多记忆样例的列表、顺序、`build_id` 和筛选结果正确；空 bundle 显示空状态；非法参数有提示；不出现跨对话记忆	`src/web/`（记忆浏览页与读取 API）
FR-13	从记忆详情回看原始证据	输入：`conversation_id`、`build_id`、`memory_id`；处理：通过 `sources` 读取 SourceTurn，按会话和轮次顺序展示说话人、时间及原文；输出：去重后的完整证据；异常：记忆不存在、版本不匹配或来源无法定位时明确报错，不生成替换文本	多来源样例中的轮次 ID、说话人和原文与 bundle 一致；重复来源只显示一次；错误引用不显示伪造文本	`src/web/`（记忆详情与证据视图）
FR-14	在 Web 界面提交问题并查看依据	输入：`conversation_id`、当前 `build_id` 和非空问题；处理：调用检索、状态解析和答案生成，Web 层不改写判定；输出：答案、Memory ID、`build_id` 和证据入口；异常：空问题、未知对话、版本不匹配或后端失败时显示错误，不残留上一次答案	页面答案与 AnswerRecord 一致；切换对话或构建后不残留旧结果；错误可理解；Web 操作不改变命令行评测输出	`src/web/`（问答页面与问答 API）
FR-15	可视化查询涉及的状态关系与演化	输入：MemoryRelation、相关 Memory 和来源；处理：按关系方向绘制节点，区分 RETAIN、UPDATE、SUPERSEDE、CONFLICT，并突出有效记忆；输出：关系视图、图例和空状态；异常：未知类型显示原始标签；引用缺失或版本不一致时不绘制错误连线	四种关系样例的标签、端点 ID、方向和证据跳转与输入一致；空关系及未知类型可显示；前端不自行增删关系	`src/web/`（状态演化与关系可视化）

3.5 评测与课程接口

3.5.1 描述与优先级

系统提供参数化命令行入口，并计算问答质量、证据检索和状态更新判断三类指标。该功能是课程验收和最终对照分析的必要条件，优先级为“必须”。

3.5.2 刺激—响应序列

- 评测脚本提交对话和问题参数：系统逐题运行并以固定题号写入 `answers.json`。
- 评测数据包含 gold evidence 和答案：系统仅用其计算指标，不将其送入构建或推理流程。
- 方案冻结后运行测试集：系统按同一配置运行本组方法和两个基线，输出可横向比较的结果。

3.5.3 功能需求

编号	需求	验收依据	实现位置
FR-16	提供参数化的课程评测入口，接收对话编号与问题参数，并把答案写入结果文件	按 6.2 节命令运行能生成 `answers.json`，每题一句话答案并标明题号	`src/eval/`（未实现）
FR-17	计算问题回答 F1、证据记忆检索 Recall@K、状态更新判断准确率	三项指标均能在开发集计算，并可按问题类别细分	`src/eval/`（未实现）
FR-18	支持与 Full Text、Vector RAG 基线在同表对照，并记录平均 token	结果表包含三种方法及四项数值，实验配置可复现	`experiments/`

4. 外部接口需求

本项目无专用硬件接口和物理控制接口，因此按模板裁剪 Hardware Interfaces；其余适用接口如下。

4.1 用户界面

编号	界面	要求
UI-01	记忆浏览页	选择对话，展示记忆、筛选条件、来源数量和当前 `build_id`
UI-02	记忆与证据详情页	展示结构化字段和原始说话人、会话、轮次及原文，并支持证据去重
UI-03	问答与状态关系页	提交问题，展示答案、有效记忆、四类关系、图例和证据入口；必须区分空状态和错误状态

4.2 软件接口

编号	接口或依赖	交互内容
SI-01	LoCoMo 文件	从根目录 `locomo.json` 读取对话和 QA；构建与检索不得读取 QA 标注、标准答案或 gold evidence 作为输入
SI-02	DeepSeek 官方 API	用于记忆抽取、Query 分析和答案生成；通过环境变量提供密钥，关闭 thinking，非法输出按 FR-02、FR-08、FR-10 处理
SI-03	本地 MiniLM 模型	对 Memory 和问题生成向量；固定 revision，向量缓存绑定模型身份与 `build_id`
SI-04	项目内部 Python 接口	使用 `MemoryBundle`、`RetrievalResult`、`MemoryRelation`、`AnswerRecord`；字段与签名以 `interfaces.md` 为准
SI-05	课程评测入口	接收对话编号和问题参数，输出 `answers.json`；不得依赖 Web 服务

4.3 通信接口

编号	通信	要求
CI-01	DeepSeek HTTPS API	使用官方端点；对超时、限流和网络错误执行有界重试；不得在日志中输出密钥或完整敏感请求
CI-02	Web 前后端通信	前端与本地后端交换 JSON；响应必须携带结果实际所属的 `build_id`，错误使用可区分状态返回
CI-03	命令行文件通信	UTF-8 编码读写 JSON；输出原子写入，避免中断导致半写文件

5. 其他非功能需求

5.1 性能需求

编号	需求	验收依据
NFR-05	检索应复用已建索引和记忆向量，不重复调用抽取 API；抽取重试、分块和返回条数必须有界。单题状态解析与答案生成必须记录时间和 token；在实验室网络、排除极端超时重试样本时，状态判定平均耗时不超过 8 秒，答案生成平均耗时不超过 6 秒	连续查询记录数据规模、设备、构建耗时和查询耗时；验证 Top-K 上限与缓存复用；不把首次模型加载计入稳态查询；每题 token 可进入 Full Text、Vector RAG 和本组方法对照表

5.2 安全需求

编号	需求	验收依据
NFR-06	原始对话按不可信数据处理，只作为分析对象，不执行其中的指令；模型输出非法、构建版本不一致或证据不可定位时不得伪造成功结果；写入失败不得破坏已有 MemoryBundle	注入包含指令的合成对话，确认不会改变系统规则或读取 QA 标注；模拟非法 JSON、版本冲突和写入中断，确认系统报错且原文件仍可读取

5.3 信息安全需求

编号	需求	验收依据
NFR-04	密钥只从环境变量或本地 `.env` 获取，不写入源码、JSON、缓存、日志或版本库；标注答案与 gold evidence 只能用于评测，不得进入构建、索引或模型输入；系统不得默认暴露到公网	检查提交内容和运行产物；注入合成标签后确认构建不受影响；构造鉴权失败场景，确认响应不泄漏敏感正文

5.4 软件质量属性

编号	属性	需求	验收依据
NFR-01	可复现性	固定直接依赖、模型 revision、输入哈希、抽取配置和 prompt 版本；构建结果由响应缓存复用；相同输入与配置产生一致的结构化输出	重复构建并比较 `build_id`、Memory ID 和检索排名；新配置使用不同缓存身份；不承诺未缓存的远端模型逐字确定；固定问题集连续运行两次时关系类型和有效记忆 ID 一致
NFR-02	跨平台性	Python 3.11 为协作基准；macOS 和 Windows 分别建立虚拟环境；统一使用 UTF-8 与 `pathlib`	两平台分别安装依赖，运行基础测试和命令行演示并记录系统、Python 版本和结果；单一平台通过不能代替双平台验收
NFR-03	可追溯性	Memory、检索候选、证据和状态解析引用绑定同一对话和 `build_id`；每条答案和关系均可定位到 Memory 与原始轮次	检查全部导出 Memory 的来源存在；每条命中可定位原轮次；混用构建时明确失败；随机抽取 20 条 AnswerRecord 核对回溯校验，定位失败率为 0

6. 其他需求

6.1 评测数据、指标与基线

项目	规定
数据划分	课程从 10 段 LoCoMo 对话中选择 6 段：开发集为 `conv-26`、`conv-30`、`conv-41`、`conv-42`；课程从其余 6 段中任意选取 2 段作为独立测试集；其余 4 段可作扩展
数据隔离	开发集用于 prompt、检索参数和 K 值调试；测试集只在方案冻结后运行；标准答案、gold evidence、事件摘要和问题类型标签只用于评测
M-1 问答 F1	使用 LoCoMo 官方词级 F1 口径，汇总开发集与测试集结果
M-2 Recall@K	将 gold evidence 对齐到 Memory 来源；前 K 条结果覆盖该题至少一条关键证据即为命中；至少报告 Recall@1 和 Recall@5
M-3 状态更新准确率	统计 RETAIN、UPDATE、SUPERSEDE、CONFLICT 判定正确比例，并按类别报告混淆矩阵
Full Text 基线	不进行检索和状态解析，将对话按官方 baseline 口径送入模型，记录平均 token
Vector RAG 基线	只按向量相似度取 Top-K 后生成答案，不进行状态关系判断
本组方法	多路检索 → 状态解析过滤 → 生成答案，即第 3 章全部功能需求

6.2 课程评测接口

数据文件 `locomo.json` 位于仓库根目录。评测入口必须支持以下调用形式；最终参数和结果字段以助教通知为准：

```
python [评测入口] --conversation [conv_id] --questions [questions.json] --output answers.json
```

输出要求：每题提供一句话答案并标明题号，保存为 UTF-8 JSON；内部 Memory 格式不要求与课程统一。

6.3 结果与可复现性

三项指标与平均 token 必须按方法分行汇总，并分别记录开发集与测试集结果。实验配置、日志和错误案例保存在 `experiments/`；相同输入和配置应可复现。任一必需指标无法计算，视为对应功能需求未完成。

6.4 需求追踪

功能	功能需求	验证依据	主要交付位置
FE-01	FR-01–FR-03	Memory、来源、版本和原子写入测试	`src/memory/`、`src/common/`
FE-02	FR-04–FR-07	检索排序、融合去重和证据回溯测试	`src/index/`、`src/memory/`
FE-03	FR-08–FR-11	关系准确率、有效记忆选择和答案追溯测试	`src/reasoning/`
FE-04	FR-12–FR-15	Web 页面、错误状态和关系视图测试	`src/web/`
FE-05	FR-16–FR-18	`answers.json`、M-1/M-2/M-3 和基线结果表	`src/eval/`、`experiments/`

详细“需求 → 实现 → 测试用例 → 指标”映射在设计与测试阶段维护；新增或修改需求时必须同步更新本表。

附录 A：词汇表

术语	定义
Memory	从原始对话抽取的一条可验证事实，包含内容、时间与来源轮次
MemoryBundle	一段对话的全部记忆、来源和构建版本信息
SourceTurn / SourceRef	原始对话轮次 / 对轮次的引用；评测证据键为 `(conversation_id, session_id, turn_id)`
build_id	一次记忆构建的唯一版本标识；索引、检索、推理和实验记录必须引用一致版本
RETAIN	两条记忆均有效，可以同时成立
UPDATE / SUPERSEDE	新记忆更新或替代旧记忆，旧记忆不再是当前有效状态
CONFLICT	两条记忆不能同时成立，且现有证据不足以消解冲突
有效记忆	在当前问题和时间条件下仍然成立的记忆子集
gold evidence	LoCoMo 为 QA 标注的证据轮次；仅用于评测，不得进入构建或模型输入
BM25	基于词项统计的关键词检索排序函数
RRF	Reciprocal Rank Fusion，按排名合并多路检索结果；本项目等权，使用 `sum(1/(60+rank))`
Recall@K	前 K 条检索结果是否覆盖该题的关键证据
QA F1	生成答案与标准答案之间的词级 F1 分数

附录 B：分析模型

B.1 端到端数据流

```
原始对话 → 清洗 → 结构化 MemoryBundle
问题 → Query 分析 → BM25 / 向量 / hybrid 检索 → 候选 Memory
候选 Memory → 状态关系判定 → 有效 Memory → 答案生成
Memory + 证据 + 状态关系 → Web 展示
答案 + gold evidence → M-1 / M-2 / M-3 → 基线对照
```

B.2 状态关系模型

关系	判定含义	对后续答案的影响
RETAIN	两条记忆可同时成立	均作为有效记忆候选
UPDATE	新事实延续并更新同一状态	合并为当前有效状态，同时保留历史来源
SUPERSEDE	新事实替代旧状态	仅新值进入答案生成，旧值可追溯但不参与作答
CONFLICT	两条事实互斥且无法可靠消解	两条均保留并标记冲突，不得单方面隐去一条

附录 C：待决问题

编号	问题	影响	责任人 / 处理节点
I-01	课程已公布开发集为 `conv-26`、`conv-30`、`conv-41`、`conv-42`；独立测试集由课程从其余 6 段中任意选取 2 段，具体 `sample_id` 尚未确定	开发集可用于调试；测试集身份未知，不能使用候选对话调参	陈易；在课程通知测试数据后更新评测配置
I-02	课程最终评测入口参数和 `answers.json` 字段仍可能调整	影响 FR-16 的最终适配	陈易；以助教最终通知为准
I-03	官方 LoCoMo 基线与当前 SDK、运行设备存在兼容差异	可能影响 Full Text 和 Vector RAG 实验的可执行性	张崇洋；实验中记录兼容改动和配置，不改变对照口径