

「Project Proposal」

长程对话动态状态解析 与有效记忆管理

基于 LoCoMo 数据集的结构化抽取、动态状态判定与有效记忆检索系统

课程领域

大语言模型与长程对话记忆

方案定位

检索 + 动态状态关系解析

汇报人

陈易 · 鲁瑞特 · 于国庆 · 许子萌 · 张崇洋

汇报日期

10/9

一、问题背景与痛点：状态演化与过期记忆挑战

仅检索相关信息无法判断有效性，必须显式判定记忆保留、更新替代或冲突

01 长程对话中状态持续变化

用户的工作、居住、计划、偏好等信息在多会话之间不断被更新，例如从“在准备领养申请”演进到“通过领养面试”。

02 普通向量检索无法区分新旧信息

仅按语义相似度召回，可能同时召回**当前状态**与已被后续信息更新的历史状态，模型无法判断哪条仍然有效。

03 错误决策与过期答案隐蔽性高

系统基于已失效的历史状态回答当前问题，产生错误回答或错误决策，且错误往往难以在生成端被直接察觉。

04 LoCoMo 课程数据特征

每段对话平均 **588.2 轮**、**27.2 个会话**、约 **1.66 万 token**，并提供问答、证据轮次与事件摘要标注，真实刻画状态演化。

核心判断

仅“检索到相关信息”并不足够，还需要显式判断记忆之间是 **RETAIN**、**UPDATE (SUPERSEDE)** 还是 **CONFLICT**，才能确定当前有效记忆。

二、目标范围：五大核心交付与端到端系统边界

构建从原始对话到动态状态解析、有效记忆检索、Web 展示与基准评测的闭环

01 结构化记忆构建

从原始对话抽取人物、事件、时间、状态，统一导出为 **JSON 格式**，并可精确回溯到原始对话出处轮次。

02 动态状态解析

判定记忆之间的 **RETAIN / UPDATE (SUPERSEDE) / CONFLICT** 关系，精准过滤过期状态，确定当前有效记忆。

03 有效记忆检索与生成

采用两阶段链路：检索相关记忆 → 解析状态 → 调用 **DeepSeek API** 生成最终准确答案。

04 Web 应用与可视化

搭建轻量 Web 界面，直观展示**结构化记忆**、原始证据轮次以及状态演化过程与关系视图。

05 评测与对照分析

按三个量化指标系统评测，并与 **Full Text**、**Vector RAG** 两种主流基准方法展开全面对照分析。

边界原则

聚焦核心算法与状态判定机制，不进行模型训练或微调；后续根据实验结果决定是否增加维度检索或图关系检索，控制实现复杂度。

三、数据方案：LoCoMo 对话抽取与 Memory 规范

从 6 段原始对话构建原子事实 Memory，严格隔离金标准与答案，确保证据可回溯

数据范围与清洗

使用课程指定 **6 段 LoCoMo 对话**（4 段开发、2 段独立测试，编号待公布）；仅从原始对话构建记忆，过滤图片链接与多模态字段，gold evidence、标准答案及标注摘要严格不进入抽取与检索。

抽取与 Memory 结构

按会话分块将人物、事件和状态抽取为原子事实。每条记录包含**唯一 ID**、事实内容、实体/属性/值、会话时间、事件时间及来源轮次列表；前后状态分别保留供推理模块判定。

存储与两路召回

按对话导出并复用 outputs/memory/<conversation_id>.json，配套原始证据；已实现 **BM25 与 MiniLM 向量召回**，通过 RRF 按 Memory ID 合并去重与排序。

示例与验收重点

课件第 12 页 Caroline / D19:1“上周五通过领养面试”，抽取为 Caroline · adoption_status · passed adoption agency interviews（保留 last Friday 与原始证据）。**验收重点**：JSON 可读写、证据可回溯、对话间不串库。

四、技术方案：两阶段检索与四类状态关系判定

核心思路：不直接把历史检索结果交给模型，而在生成前增加一层“动态状态解析”

整体处理流水线

记忆构建（抽取原子事实保留证据轮次） → 多路检索（BM25+MiniLM 向量召回） → Query 分析（提取人物/时间/属性/事件/状态 5 维约束） → 动态状态关系判定 → 有效记忆选择 → DeepSeek 答案生成。

● RETAIN

两条记忆描述的是可以**同时成立**的信息，不需要替换，共同保留。

● UPDATE

后续信息对已有状态进行了**补充或修改**，应使用更新后的状态。

● SUPERSEDE

新记忆**明确取代旧记忆**，旧状态不再作为当前有效状态使用。

● CONFLICT

两条记忆存在**无法同时成立的矛盾**，结合时间、上下文与证据进一步仲裁。


方案取舍与技术优势

参考 [DimMem](#) 结构化记忆与 [MRAgent](#) 主动检索思想，重点聚焦四类状态关系判定；不微调模型，统一调用 [DeepSeek API](#) 完成抽取、判断与生成。

五、系统架构与界面设想：离线/在线双链路与交互视图

离线完成记忆构建与索引，在线实现多路检索、状态解析、DeepSeek 答案生成与演化展示

离线：记忆构建



问答主页面

展示用户问题、生成答案及引用的有效记忆。

记忆浏览页

按对话完整查看导出的结构化 Memory JSON。

证据详情页

点击记忆可精确回看对应的原始对话轮次。

状态演化视图

动态展示 RETAIN、UPDATE、SUPERSEDE、CONFLICT 关系及当前有效状态。

模块与接口规范

后端调用 src/memory/、src/index/、src/reasoning/ Python 接口，接口以 docs/interfaces.md 为准，前后端解耦。

六、评测方案与预期指标：三维量化指标与双基准对照

系统评估答案质量、检索召回与状态判断准确率，与 Full Text 和 Vector RAG 全面对照

问题回答 F1

使用 LoCoMo 官方评测脚本，计算系统答案与标准答案的**词级 F1**，汇总报告平均值。

证据检索 Recall@K

将 gold evidence 对齐到原始证据轮次，分别报告 **Recall@1** 与 **Recall@5**，监控检索覆盖率。

状态更新准确率

评估 **RETAIN / UPDATE / SUPERSEDE / CONFLICT** 4 类关系判定准确率与混淆情况，避免中间错误被掩盖。

评测指标与基准方法对比框架



F1、平均 token 及本组状态准确率待测；
Full Text 的检索与状态指标、Vector RAG 的状态指标不适用。

对照实验设计

统一对比 **Full Text**（全文输入）、**Vector RAG**（仅向量检索不解析状态）与**本组方法**（记忆构建+检索+状态解析）。

数据划分与日志

4 段开发集用于调参，2 段测试集用于最终盲测验证；评测入口接收 locomo.json 并输出标准 answers.json，同步记录平均 token。

七、功能路线图：五大里程碑演进与推进时序

6 周周期内完成五个里程碑，每个里程碑安排两轮迭代并预留独立缓冲时段

里程碑 1-2 · 10/10 截止 团队工作流与 Proposal 展示 交付团队工作流文档与 Proposal 演示（10/9 展示）；完成分工与计划确定，方案获得认可。	里程碑 3-4 · 10/24 截止 规格说明、编码与端到端跑通 交付需求规格说明书、设计编码与测试；实现端到端流水线跑通：一段对话 → 记忆 → 检索 → 状态解析 → 答案。	里程碑 5 · 11/9 截止 最终报告与系统交付 交付最终报告与完整可运行系统；完成三指标评测与 baseline 对照分析。
--	--	---

推进时序	核心功能推进顺序：记忆构建 → 检索 → 状态关系判定 → 答案生成 → Web 可视化 → 评测与对照实验。
------	---

八、分工与计划：五人模块化分工与关键节点

职责边界清晰、模块接口先行，确保各模块并行推进与平滑集成

陈易	鲁瑞特	于国庆	许子萌	张崇洋
项目管理与集成架构	数据、记忆与检索基础设施	动态状态解析与推理	Web 与可视化界面	评测与文档
负责计划与追踪、仓库与权限、架构决策、集成与评测接口、演示环境搭建。	负责 Memory 结构设计、结构化抽取、JSON 导出与检索接口实现。	负责关系判定、有效记忆选择、Prompt 工程与 DeepSeek 答案生成。	负责记忆与证据视图、状态演化展示与演示素材准备。	负责三指标评测、基准对照实验、文档定稿与 Slides 排版。

关键节点	10/10 提交里程碑 1、2（Proposal 于 10/9 展示）；10/24 提交里程碑 3、4；11/9 提交最终报告。
------	--

九、风险与可行性小结：四大风险应对与可行性结论

课题难度适中、边界清晰、技术成熟、双轮迭代，能在课程周期内高质量交付

● 风险 01· 状态关系判定效果不及预期

影响：影响最终答题正确率。**应对：**关键路径成员只做核心算法，不承担辅助工作；先跑通机制再持续优化。

● 风险 02· 检索召回不足放大下游错误

影响：证据缺失导致答错。**应对：**设计多路检索并做去重合并，使用 Recall@K 单独监控检索环节。

● 风险 03· 6 周完成五个里程碑时间紧

影响：中期与最终延期。**应对：**每个里程碑两轮迭代 + 独立缓冲时段；功能优先跑通端到端。

● 风险 04· 课程评测所用对话不公开

影响：可能出现过拟合诱惑。**应对：**严格不使用 gold evidence 与答案，所有规则保持通用。

可行性结论

课题难度适中且边界清晰，所需技术均有成熟方案可参考；团队按模块分工、接口先行、双轮迭代推进，**能在课程周期内交付可运行系统、结构化记忆 JSON、评测结果与项目报告。**